

# **Test Technique Quantmetry**

### **Objectif**

Cet exercice a pour objectif d'évaluer vos compétences en data science, à travers votre connaissance des statistiques, de l'apprentissage automatique, et vos capacités en programmation.

### Votre rendu comportera:

- Un document de réponse aux questions d'une longueur de 6 pages au maximum (format PDF ou Word).
- Un dossier zippé contenant votre code R ou Python (précisez la version utilisée).

Votre code devra pouvoir être rejoué facilement. N'hésitez pas à inclure un README.

#### Enoncé

Le jeu de données contenu dans data.csv décrit des candidatures au poste de chercheur d'or chez OrFée. Votre objectif consiste à prédire le succès ou l'échec d'une candidature.

Le jeu de données comporte 11 colonnes :

- date date de la candidature
- age âge du candidat
- diplome plus haut diplôme obtenu (bac, licence, master, doctorat)
- specialite spécialité du diplôme (géologie, forage, détective, archéologie, . . . )
- salaire salaire demandé
- dispo oui : disponibilité immédiate, non : pas disponible immédiatement
- sexe féminin (F) ou masculin (M)
- exp nombre d'années d'expérience
- *cheveux* couleur des cheveux (châtain, brun, blond, roux)
- note note (sur 100) obtenue à l'exercice de recherche d'or
- embauche le candidat a-t-il été embauché ? (0 : non, 1 : oui)



### 1. Statistiques descriptives

- 1. Décrivez le jeu de données. Présentez seulement les analyses et éventuels retraitements qui vous paraissent les plus pertinents et faites une première conclusion sur les variables à sélectionner en vue de la prédiction du succès ou de l'échec d'une candidature.
- 2. Y a-t-il une dépendance statistiquement significative entre :
  - (a) La spécialité et le sexe ?
  - (b) La couleur de cheveux et le salaire demandé?
  - (c) Le nombre d'années d'expérience et la note à l'exercice ?

## 2. Machine Learning

- 1. Concevez un modèle permettant de prédire la variable embauche et expliquez votre choix d'algorithme. Si votre modèle comporte des spécificités de paramétrage, justifiez également vos choix de paramètres.
- 2. Quelles sont les variables les plus importantes de votre modèle ? Commentez.
- 3. Décrivez et justifiez le critère de performance utilisé.
- 4. Proposez deux à trois pistes d'amélioration de votre modèle.